Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»

Рубежный контроль №1

по дисциплине

«Методы машинного обучения»

Вариант №3. набор данных №8.

Выполнил: студент группы ИУ5-21М Исмаил Ахмад

Москва — 2020 г.

1.1. Задание

Для заданного набора данных произведите масштабирование данных (для одного

признака) и преобразование категориальных признаков в количественные двумя способами (label encoding, one hot encoding) для одного признака. Какие методы Вы использовали для решения задачи и почему?

1.2. Решение

1.2.1. Загрузка и предобработка данных

```
In [1]: import numpy as np
       import pandas as pd
       import seaborn as sns
       %matplotlib inline
       /usr/local/lib/python3.6/dist-packages/statsmodels/tools/_testing.py:19: FutureWarning: pandas.util.testin
       g is deprecated. Use the functions in the public API at pandas.testing instead.
        import pandas.util.testing as tm
In [0]: data = pd.read csv("/content/sample data/FIFA 2018 Statistics.csv")
In [3]: data.dtypes
Out[3]: Date
                               object
                               object
       Team
                               object
       Opponent
       Goal Scored
                               int64
       Ball Possession %
                               int64
                               int64
       Attempts
       On-Target
                               int64
       Off-Target
                                int64
                               int64
       Blocked
                               int64
       Corners
       Offsides
                               int64
       Free Kicks
                               int64
       Saves
                                int64
       Pass Accuracy % int64
                                int64
       Distance Covered (Kms) int64
       Fouls Committed
                                int64
       Yellow Card
                                int64
       Yellow & Red
                                int64
       Red
                                int64
```

Man of the Match object
1st Goal float64
Round object
PSO object
Goals in PSO int64
Own goals float64
Own goal Time float64
dtype: object

In [4]: data.head()

Out[4]:

	Date	Team	Opponent	Goal Scored	Ball Possession %	Attempts	On- Target	Off- Target	Blocked	Corners	Offsides	Free Kicks	Saves	Pas Ace
0	14- 06- 2018	Russia	Saudi Arabia	5	40	13	7	3	3	6	3	11	0	78
1	14- 06- 2018	Saudi Arabia	Russia	0	60	6	0	3	3	2	1	25	2	86
2	15- 06- 2018	Egypt	Uruguay	0	43	8	3	3	2	0	1	7	3	78
3	15- 06- 2018	Uruguay	Egypt	1	57	14	4	6	4	5	1	13	3	86
4	15- 06- 2018	Morocco	Iran	0	64	13	3	6	4	5	0	14	2	86

In [5]: data.shape

Out[5]: (128, 27)

```
In [6]: data.isnull().sum()
```

In [0]. data:IShall().Sa

0 Out[6]: Date 0 Team Opponent 0 Goal Scored 0 Ball Possession % 0 Attempts 0 On-Target 0 Off-Target 0 Blocked 0 Corners 0 Offsides 0 Free Kicks 0 Saves Pass Accuracy % Passes Distance Covered (Kms) 0 Fouls Committed 0 Yellow Card 0 Yellow & Red 0 Red 0 Man of the Match 0 1st Goal 34 Round 0 PS0 0 Goals in PSO 0 Own goals 116 Own goal Time 116 dtype: int64

```
In [0]: d = data[["Corners", "Distance Covered (Kms)", "Round"]]
d = d.dropna(axis=0, how="any")
In [8]: d.head()
Out[8]:
             Corners | Distance Covered (Kms) | Round
          0
             6
                       118
                                                Group Stage
           1
             2
                       105
                                                Group Stage
          2 0
                       112
                                                Group Stage
          3 5
                       111
                                                Group Stage
           4 5
                       101
                                                Group Stage
In [9]: d.shape
Out[9]: (128, 3)
In [10]: sns.distplot(d[["Distance Covered (Kms)"]]);
           0.07
           0.06
           0.05
           0.04
           0.03
           0.02
           0.01
           0.00
                              100
                                        120
                                                  140
In [11]: from sklearn.preprocessing import MinMaxScaler
          sc = MinMaxScaler()
          sc_data = sc.fit_transform(d[["Distance Covered (Kms)"]])
          sns.distplot(sc_data)
Out[11]: <matplotlib.axes._subplots.AxesSubplot at 0x7f50c99d0b38>
           2
           1
```

0.2

In [0]: d["Distance Covered (Kms)_SCALED"] = sc_data

0.4

0.8

1.2.3. Преобразование категориальных признаков

```
In [0]: from sklearn.preprocessing import LabelEncoder, OneHotEncoder
         Label encoding
 In [0]: le = LabelEncoder()
          Round_le = le.fit_transform(d["Round"])
In [25]: np.unique(Round_le)
Out[25]: array([0, 1, 2, 3, 4, 5])
In [26]: le.inverse transform(np.unique(Round le))
Out[26]: array(['3rd Place', 'Final', 'Group Stage', 'Quarter Finals',
                  'Round of 16', 'Semi- Finals'], dtype=object)
 In [0]: d["Round INDEX"] = Round le
          One Hot encoding
 In [0]: ohe = OneHotEncoder()
          Round_ohe = ohe.fit_transform(d[["Round"]])
In [30]: Round_ohe.todense()[0:10]
Out[30]: matrix([[0., 0., 1., 0., 0., 0.],
                  [0., 0., 1., 0., 0., 0.],
                  [0., 0., 1., 0., 0., 0.],
                  [0., 0., 1., 0., 0., 0.],
                  [0., 0., 1., 0., 0., 0.],
                  [0., 0., 1., 0., 0., 0.],
                  [0., 0., 1., 0., 0., 0.],
                  [0., 0., 1., 0., 0., 0.],
                  [0., 0., 1., 0., 0., 0.],
                  [0., 0., 1., 0., 0., 0.]])
In [31]: d["Round"].head(10)
Out[31]: 0
               Group Stage
               Group Stage
               Group Stage
          3
               Group Stage
          4
               Group Stage
               Group Stage
          5
          6
               Group Stage
          7
               Group Stage
               Group Stage
               Group Stage
          Name: Round, dtype: object
In [32]: ohe_names = ohe.get_feature_names()
          ohe_names
Out[32]: array(['x0_3rd Place', 'x0_Final', 'x0_Group Stage', 'x0_Quarter Finals', 'x0_Round of 16', 'x0_Semi- Finals'], dtype=object)
```

```
In [0]: for idx, name in enumerate(ohe_names):
    d[name] = Round_ohe[:, idx].todense()
```

Получившийся набор данных

In [35]: d.head(10)

Out[35]:

	Corners	Distance Covered (Kms)	Round	Distance Covered (Kms)_SCALED	Round_INDEX	x0_3rd Place	x0_Final	x0_Group Stage	x0_Quarter Finals	x0_Round of 16	x0_Se Finals
0	6	118	Group Stage	0.558824	2	0.0	0.0	1.0	0.0	0.0	0.0
1	2	105	Group Stage	0.367647	2	0.0	0.0	1.0	0.0	0.0	0.0
2	0	112	Group Stage	0.470588	2	0.0	0.0	1.0	0.0	0.0	0.0
3	5	111	Group Stage	0.455882	2	0.0	0.0	1.0	0.0	0.0	0.0
4	5	101	Group Stage	0.308824	2	0.0	0.0	1.0	0.0	0.0	0.0
5	2	100	Group Stage	0.294118	2	0.0	0.0	1.0	0.0	0.0	0.0
6	4	102	Group Stage	0.323529	2	0.0	0.0	1.0	0.0	0.0	0.0
7	5	103	Group Stage	0.338235	2	0.0	0.0	1.0	0.0	0.0	0.0
8	5	103	Group Stage	0.338235	2	0.0	0.0	1.0	0.0	0.0	0.0
9	1	111	Group Stage	0.455882	2	0.0	0.0	1.0	0.0	0.0	0.0

Метод «Label Encoding» в этом случае более эффективен и прост для кодирования столбца данных «Round» путем представления числовых данных текста: нам достаточно одного столбца, чтобы предоставить информацию для всех совпадений, в противном случае необходимо «One Hot encoding» больше столбцов данных, чтобы соответствовать матрице для каждого соответствия, поэтому я думаю, что кодировка меток лучше в нашем случае.